Raport projektowy
Uczenie się ze wzmocnieniem

Patryk Przybyło

2026/2027

Spis treści

1 Informacje podstawowe **2**

2 Temat i cel projektu **2**
2.1 Opis problemu . . . 2
2.2 Cel agenta . . . 2
2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem . . . 2

3 Formalizacja problemu RL/MDP **3**
3.1 Agent i środowisko . . . 3
3.2 Stan lub obserwacja . . . 3
3.3 Akcje . . . 4
3.4 Funkcja nagrody . . . 4
3.5 Warunki zakończenia epizodu . . . 5
3.6 Założenia i ograniczenia środowiska . . . 5

4 Implementacja **5**
4.1 Struktura repozytorium . . . 5
4.2 Środowisko . . . 5
4.3 Agent bazowy . . . 6
4.4 Agent uczący się . . . 6

5 Plan eksperymentów **6**

6 Wyniki **6**

7 Analiza i wnioski **7**

8 Instrukcja uruchomienia **7**

9 Wsparcie AI **7**

10 Literatura **8**

1 Informacje podstawowe

Element	Informacja
Imię i nazwisko	Patryk Przybyło
Numer albumu	179597
Kierunek/specjalność	EF-DI/AI
Tytuł projektu	Symulacja ramienia sortującego
Link do repozytorium	https://github.com/xcxcp/ucznie_ze_wzmocnieniem
Data oddania	Do uzupełnienia

2 Temat i cel projektu

2.1 Opis problemu

Problemem jest sterowanie manipulatorem o wielu stopniach swobody w środowisku symulacyjnym silnika fizycznego. Robot jest odzwzorowany na podstawie rzeczywistego ramienia a nauczona przez agenta strategia w symulacji ma być przeniesiona na rzeczywiste sterowanie.

2.2 Cel agenta

Na podstawie pozycji obiektu agent ma tak ustawić ramię, aby chwytak znajdował się nad obiektem w taki sposób, aby możliwe było chwycenie obiektu. Przy czym ma on unikać zderzeń z innymi obiektami i podłożem oraz nie wykonywać ruchów naruszających fizyczne ograniczenia manipulatora.

2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem

Sterowania ramieniem robota można rozpatrywać jako problem uczenia się ze wzmocnieniem, ponieważ robot podejmuje serię powiązanych ze sobą decyzji, które wpływają na jego dalsze działanie oraz na stan otoczenia. W trakcie realizacji zadania robot musi kolejno podejmować decyzje dotyczące między innymi kierunku i zakresu ruchu poszczególnych przegubów, położenia ramienia oraz wysunięcia siłownika liniowego. Decyzje te tworzą sekwencję prowadzącą od początkowego położenia robota do wykonania zadania. Każde działanie agenta zmienia stan środowiska. Przykładowo obrót podstawy, zmiana kąta ramienia lub wysunięcie siłownika wpływają na aktualne położenie chwytaka. W sterowaniu robotem istotne jest osiągnięcie końcowego celu, a nie tylko uzyskanie korzyści z pojedynczego ruchu. Przykładowo szybkie zbliżenie chwytaka do obiektu nie oznacza jeszcze sukcesu, jeżeli chwytak nie będzie ustawiony w odpowiedniej pozycji. Dlatego agent powinien uwzględniać konsekwencje swoich działań w kolejnych etapach zadania. Zastosowanie agenta uczącego się jest uzasadnione ze względu na złożoność sterowania robotem posiadającym kilka stopni swobody oraz konieczność dostosowywania ruchów do zmiennego położenia. Ręczne opracowanie reguł sterowania dla wszystkich możliwych sytuacji może być trudne i mało elastyczne. Agent uczący się ze wzmocnieniem może natomiast zdobywać doświadczenie poprzez wielokrotne wykonywanie prób w środowisku symulacyjnym.

3 Formalizacja problemu RL/MDP

3.1 Agent i środowisko

Agentem jest algorytm uczenia się ze wzmocnieniem odpowiedzialny za sterowanie ramieniem robota. Jego zadaniem jest wybieranie kolejnych ruchów prowadzących do znalezienia się chywtaka nad obiektem. Środowiskiem jest model robota oraz otoczenia przygotowany w symulatorze MuJoCo. Obejmuje ono:

- obrotową podstawę robota,
- człony ramienia i jego przeguby,
- siłownik liniowy,
- nadgarstek z niezależnymi osiami obrotu,
- chwytak wyposażony w trzy zsynchronizowane palce,
- sorotowane obiekty,
- plansza.

Agent i środowisko współpracują w następującej pętli:

1. Środowisko udostępnia agentowi aktualną obserwację.
2. Agent analizuje obserwację i wybiera akcję.
3. Akcja jest przekazywana do środowiska symulacyjnego.
4. Symulator wykonuje zadany ruch, uwzględniając mechanikę robota i oddziaływania z otoczeniem.
5. Środowisko zwraca nową obserwację, wartość nagrody oraz informację, czy epizod został zakończony.
6. Agent wykorzystuje otrzymane informacje do aktualizacji swojej strategii podczas treningu.

3.2 Stan lub obserwacja

Agent ma dostęp do informacji o kątach obrotu podstawy, przegubów ramienia i nadgarstk, wysunięciu siłownika liniowego oraz położeniu obiektów. Nie ma natomiast informacji bezpośredniej o położeniu poszczególnych części robota ani gdzie doszło do kolizcji.

Składowa stanu/obserwacji	Znaczenie
a_b	Kąt obrotu ramienia
a_r	Kąt między ramieniem a podstawą
a_l	Wysunięcie siłownika liniowego
a_e	Kąt zgięcia łokcia
a_n	Kąt obrotu nadgarskta wokół własnej osi
a_c	Kąt obrotu chwytaka względem nadgastak
x_i, y_i, z_i	Położenie obiektu

3.3 Akcje

Zbiór akcji określa, jakie działania agent może wykonywać w środowisku. W projektowanym robocie akcje dotyczą sterowania położeniem poszczególnych osi mechanizmu oraz chwytakiem. Przyjęto, że agent będzie sterował wartościami zadanymi dla napędów, a nie bezpośrednio sygnałami elektrycznymi lub PWM. Takie rozwiązanie pozwala oddzielić proces podejmowania decyzji przez agenta od niskopoziomowego sterowania silnikami. W proponowanym rozwiązaniu przestrzeń akcji jest ciągła, agent wybiera wartości zadane ruchu w określonych zakresach. Wartości akcji przekraczające dopuszczalne zakresy są odrzucane przez warstwę sterowania. Dzięki temu agent nie może wymusić ruchu prowadzącego do mechanicznego uszkodzenia robota.

Akcja	Opis
a_b	Kąt obrotu podstawy
a_e	Kąt obortu łokcia
a_n	Kąt obrotu nadgarstka
a_c	Kąt obrotu chwytaka
a_l	Wysunięcie siłownika liniowego

3.4 Funkcja nagrody

Funkcja nagrody określa, które zachowania agenta są pożądane. Jej zadaniem jest zachęcanie do poprawnego ustawienia chwytaka, a jednocześnie ograniczanie niepotrzebnych ruchów i niebezpiecznych zachowań.

$$r_t = w_u R_{\text{ustawienie}} + w_p(d_{t-1} - d_t) + w_k P_{\text{kolizja}} + w_n P_{\text{niedozwolony ruch}} + w_t \tag{1}$$

Gdzie:

- d_t - odległość chwytaka od aktualnego celu
- $R_{\text{ustawienie}}$ - nagroda za poprawne ustawienie chywtaka
- P_{kolizja} - kara za kolizje
- $P_{\text{niedozwolony ruch}}$ - kara za niedozwolony ruch
- w_t - kara za krok
- w_u, w_p, w_k, w_n - współczynniki określające znaczenie poszczególnych składników

Składnik	Proponowana wartość
w_u	100
w_p	1
w_k	-50
w_n	-50
w_t	-0.01

Nagroda za poprawne ustawienie jest największa, ponieważ stanowi główny cel zadania. Kara za kolizję i niedozwolony ruch ma ograniczać zachowania niebezpieczne. Ważne jest, aby funkcja nagrody nie zachęcała agenta do osiągania krótkoterminowych korzyści kosztem całego zadania. Przykładowo samo zbliżenie chwytaka do obiektu nie może być traktowane jako sukces.

3.5 Warunki zakończenia epizodu

Epizod oznacza pojedynczą próbę wykonania zadania. Rozpoczyna się od ustawienia robota i obiektu w określonych pozycjach początkowych, a kończy po wystąpieniu jednego z określonych zdarzeń. Epizod zostaje zakończony w następujących sytuacjach:

- Sukces: agent poprawnie umieścił chwytak nad obiektem
- Przekroczenie limitu kroków: agent nie wykonał zadania w określonej liczbie kroków.

3.6 Założenia i ograniczenia środowiska

Na potrzeby projektu przyjęto uproszczony model środowiska, który umożliwia przeprowadzenie treningu agenta w symulatorze MuJoCo. Najważniejsze założenia i uproszczenia:

- Rrobot jest odwzorowany w MuJoCo jako układ sztywnych elementów połączonych przegubami obrotowymi i przesuwnymi.
- Serwomechanizmy są traktowane jako napędy realizujące zadane pozycje. Nie odwzorowuje się w pełni wszystkich zjawisk występujących w rzeczywistych serwach, takich jak luzy przekładni, opóźnienia komunikacji czy zmiany momentu w zależności od warunków pracy.
- Agent dostaje dokładne pozycje obiektów, gdzie w rzeczywistym robocie pozycje są wyznaczane z kamer
- Model symulacyjny nie odwzorowuje idealnie rzeczywistej konstrukcji. Mogą występować różnice w masie, bezwładności, tarciu, sztywności elementów

Przyjęte uproszczenia pozwalają jednak rozpocząć trening w kontrolowanym środowisku, stopniowo zwiększać jego złożoność i przygotować algorytm do późniejszego wykorzystania w rzeczywistym systemie sortowania.

4 Implementacja

4.1 Struktura repozytorium

Należy krótko opisać strukturę repozytorium i najważniejsze pliki projektu.

```
repozytorium/
|-- src/
|-- experiments/
|-- report/
|-- results/
‘-- README.md
```

4.2 Środowisko

Należy opisać sposób implementacji środowiska, w szczególności funkcje inicjalizacji epizodu oraz wykonania kroku środowiska.

4.3 Agent bazowy

Należy opisać agenta losowego, heurystycznego albo inny baseline wykorzystany do porównania z agentem uczącym się.

4.4 Agent uczący się

Należy opisać zastosowany algorytm RL lub DRL, jego parametry oraz sposób implementacji. W przypadku Q-tab należy opisać reprezentację tablicy wartości. W przypadku DRL należy opisać wejścia modelu, wyjścia modelu, architekturę oraz sposób uczenia.

5 Plan eksperymentów

Należy opisać eksperymenty zaplanowane w celu oceny działania agenta.

Eksperyment	Co jest zmieniane?	Co jest mierzone?
E1	Do uzupełnienia	Do uzupełnienia
E2	Do uzupełnienia	Do uzupełnienia
E3	Do uzupełnienia	Do uzupełnienia

W tej sekcji należy wskazać:

- liczbę epizodów uczenia,
- liczbę powtórzeń eksperymentu albo uzasadnienie braku powtórzeń,
- parametry uczenia,
- metryki oceny,
- warianty środowiska, map lub funkcji nagrody,
- sposób porównania z agentem bazowym.

6 Wyniki

W tej sekcji należy przedstawić wyniki eksperymentów. Wyniki powinny być pokazane w postaci tabel, wykresów lub czytelnych zestawień.

Wariant	Średni zwrot	Skuteczność	Długość epizodu
Agent bazowy	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia
Agent RL/DRL	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia



Rysunek 1: Przykładowy wykres procesu uczenia agenta.

7 Analiza i wnioski

Należy zinterpretować wyniki. W tej części należy odpowiedzieć m.in. na pytania:

- Czy agent uczący się działa lepiej niż agent bazowy?
- Jak zmieniało się zachowanie agenta w trakcie uczenia?
- Które elementy środowiska były najtrudniejsze?
- Czy funkcja nagrody prowadziła do oczekiwanego zachowania?
- Czy wystąpiły przypadki niepożądanego zachowania agenta?
- Jakie są najważniejsze ograniczenia rozwiązania?

8 Instrukcja uruchomienia

Należy opisać sposób uruchomienia projektu od czystego repozytorium. Przykładowo:

```
git clone https://github.com/...
cd nazwa-repozytorium
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python src/main.py
```

Należy również wskazać, jak odtworzyć eksperymenty oraz gdzie zapisywane są wyniki.

9 Wsparcie AI

W tej sekcji należy obowiązkowo opisać wykorzystanie narzędzi sztucznej inteligencji. Jeżeli student nie korzystał z takich narzędzi, należy wpisać jednoznaczną informację, że nie korzystano ze wsparcia AI.

Data	Narzędzie/model	Cel użycia	Transkrypt / link / zakres
Do uzupełnienia	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia
Do uzupełnienia	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia

Należy zapisać transkrypty rozmów z modelami AI wraz z datą oraz nazwą modelu. Jeżeli rozmowa odbywała się poza narzędziami programistycznymi, należy dodatkowo udostępnić całą rozmowę poprzez link, o ile użyte narzędzie umożliwia takie udostępnienie.

Student powinien także wyjaśnić, które elementy wygenerowane lub zasugerowane przez AI zostały samodzielnie sprawdzone, zmodyfikowane albo odrzucone.

10 Literatura

W tej sekcji należy wskazać wykorzystane źródła: książki, artykuły naukowe, dokumentację bibliotek, materiały wykładowe oraz inne źródła użyte podczas pracy nad projektem.

Literatura

[1] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.